Actividad 1. Exploración y preprocesamiento de datos

Aprendizaje automático y minería de datos

Ángel Antón Gaitán

Actividad 1. Exploración y preprocesamiento de datos

El primer paso que he realizado es abrir un jupyter notebook a través de Anaconda Navigator ya que incluye las librerías indicadas en la actividad.

Luego ha instalado la librería de Autoviz (!pip install autoviz).

Después he importado pandas para gestionar el dataset que incluye información de toda España. He decidido filtrar la información por la provincia de Guadalajara. Esto corresponde a la primera fase de la metodología KDD que es el proceso de selección.

[5]:
```
provincia_buscada = 'GUADALAJARA'
```

[6]:
```
df_guada = df[df['Provincia'] == provincia_buscada].copy()
```

[7]:
```
print(f"Registros totales en el CSV: {len(df)}")
```
```
Registros totales en el CSV: 11865
```

[8]:
```
print(f"Registros en la provincia de {provincia_buscada}: {len(df_guada)}")
```
```
Registros en la provincia de GUADALAJARA: 92
```

[9]:
```
df_guada.head()
```

[9]:

	Provincia	Municipio	Localidad	Código postal	Dirección	Precio gasolina 95 E5	Precio gasóleo A	Tipo venta	Tipo servicio	Rótulo
5344	GUADALAJARA	ALCOLEA DEL PINAR	ALCOLEA DEL PINAR	19260	CR A-2, 132,2	1,589	1,569	P	A	REPSOL
5345	GUADALAJARA	ALCOLEA DEL PINAR	ALCOLEA DEL PINAR	19260	CR A-2, 135	1,609	1,599	P	A	REPSOL
5346	GUADALAJARA	ALGORA	ALGORA	19268	AUTOVIA NORDESTE KM. 112	1,679	1,639	P	A	CEPSA
5347	GUADALAJARA	ALMADRONES	ALMADRONES	19490	AUTOVIA A-2 KM. 101,8	1,579	1,615	P	A	CEPSA
5348	GUADALAJARA	ALMADRONES	ALMADRONES	19490	AUTOVIA A-2 KM. 103	1,579	1,615	P	A	CEPSA

[10]:
```
valores_nulos = df_guada.isnull().sum()
```

[15]:
```
print("\nValores faltantes por columna en Guadalajara:")
print(valores_nulos[valores_nulos > 0])
```
```
Valores faltantes por columna en Guadalajara:
Precio gasolina 95 E5    11
Precio gasóleo A          5
Tipo servicio             8
dtype: int64
```

[14]:
```
print("\nEjemplo de estaciones con datos faltantes en el precio:")
df_nulos = df_guada[df_guada['Precio gasolina 95 E5'].isnull() | df_guada['Precio gasóleo A'].isnull()]
df_nulos.head()
```

Ejemplo de estaciones con datos faltantes en el precio:

[14]:

	Provincia	Municipio	Localidad	Código postal	Dirección	Precio gasolina 95 E5	Precio gasóleo A	Tipo venta	Tipo servicio	Rótulo
5353	GUADALAJARA	ALOVERA	ALOVERA	19208	CARRETERA A-2 KM 47,5 (SALIDA 48). CTRA. MADRI...	NaN	NaN	P	A	NATURGY
5371	GUADALAJARA	CABANILLAS DEL CAMPO	CABANILLAS DEL CAMPO	19171	POLIGONO FRANCISCO MEDINA Y MENDOZA PARCELA 10...	NaN	1,356	R	A	ATA
5372	GUADALAJARA	CAMPILLO DE DUEÑAS	CAMPILLO DE DUEÑAS	19360	DISEMINADO PG 15 PARCELA 29, S/N	NaN	1,379	P	NaN	SDAD COOP CAMPILLO DE DUEÑAS
5377	GUADALAJARA	CUBILLO DE UCEDA (EL)	CUBILLO DE UCEDA (EL)	19186	CALLE NUEVA, S/N	NaN	NaN	R	A	ASOC. AGRIC. Y GANA. CUBILLO DE UCEDA
5380	GUADALAJARA	GUADALAJARA	GUADALAJARA	19001	CALLE FRANCISCO ARITIO, 16	NaN	1,349	P	D	SIMON GRUP

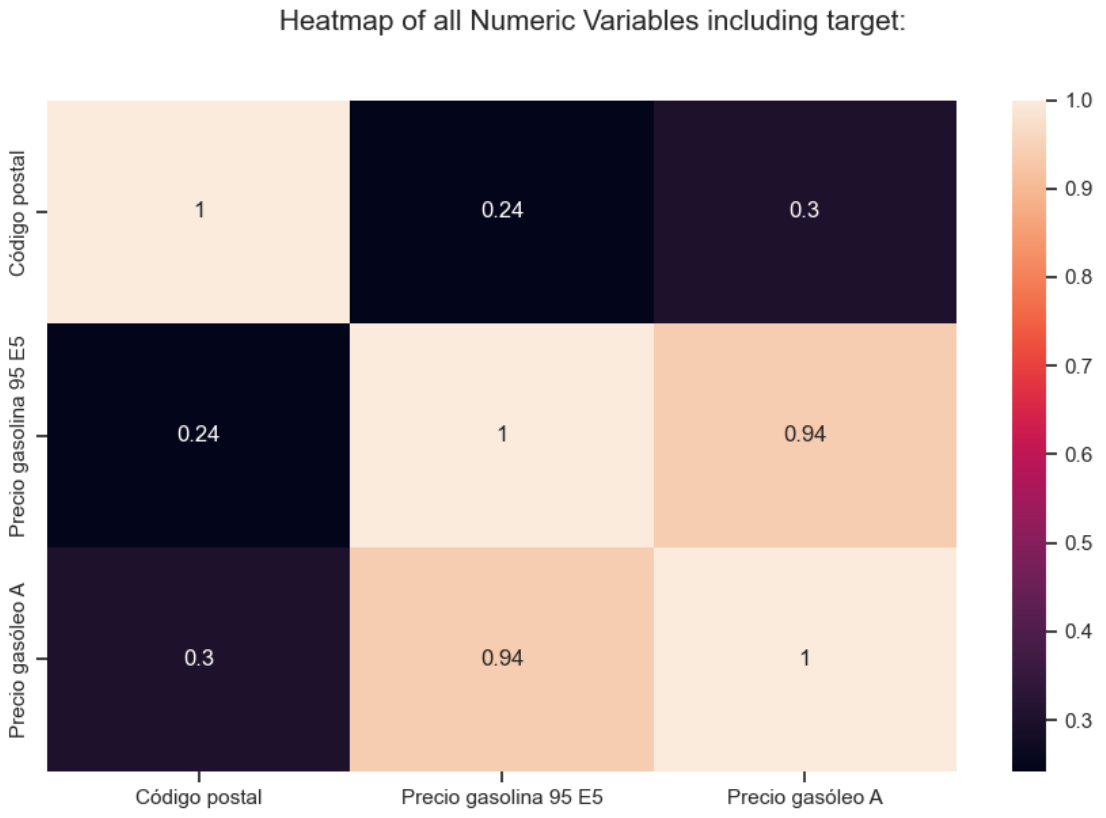
Aunque las primeras filas no mostraban anomalías, un análisis de valores nulos indica que hay datos que faltan (NaN), por lo que, según la metodología KDD se requiere limpieza de datos en esos registros para eliminar o imputar datos, evitando así errores.

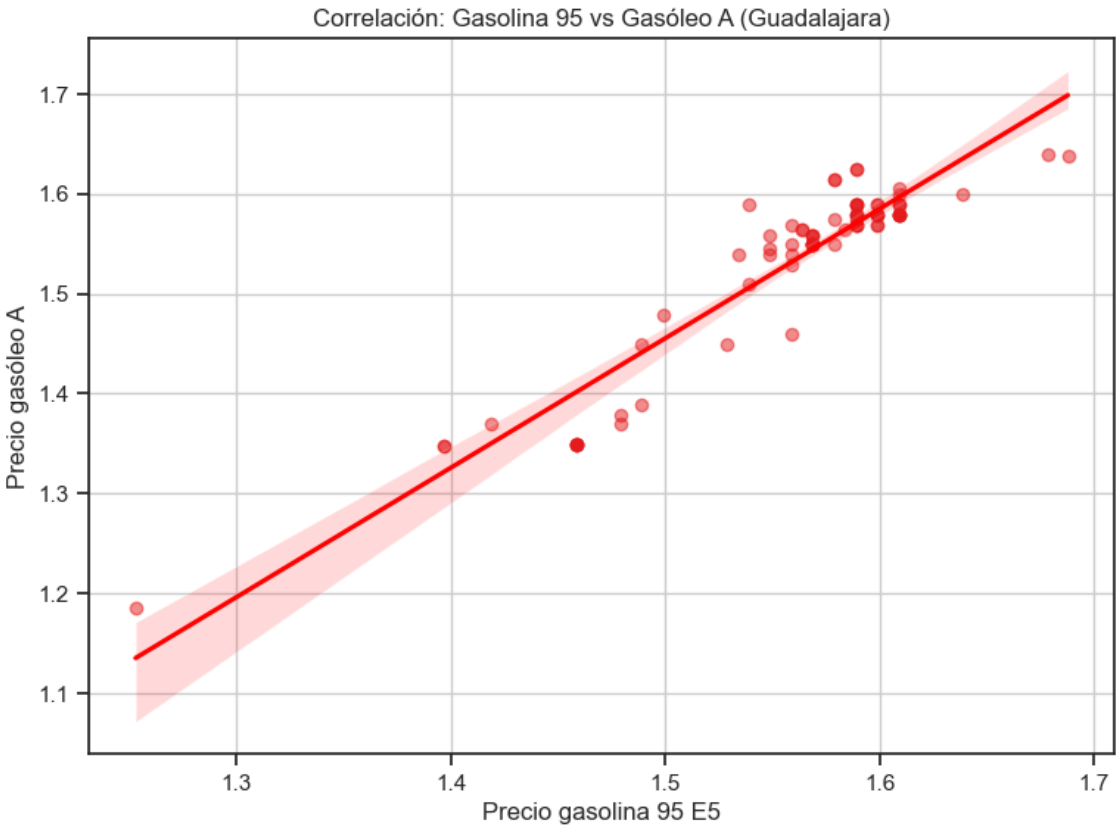
Al ejecutar autoviz, interpreta como texto los precios de carburantes porque los decimales están escritos con coma y Python y Pandas usan punto. Por lo tanto, tuve que convertir dichos datos a número y cambiar las comas por puntos.

Tras ejecutarlo, observamos que los datos son numéricos continuos para los precios de los combustibles (float); numéricos enteros para el código postal (integer); categóricos para tipo de servicio, municipio, localidad y rótulo (String); boleano para tipo de venta y NLP (Natural Language Processing) para dirección. También se observa que se recomienda no considerar la columna provincia para el modelado de datos.

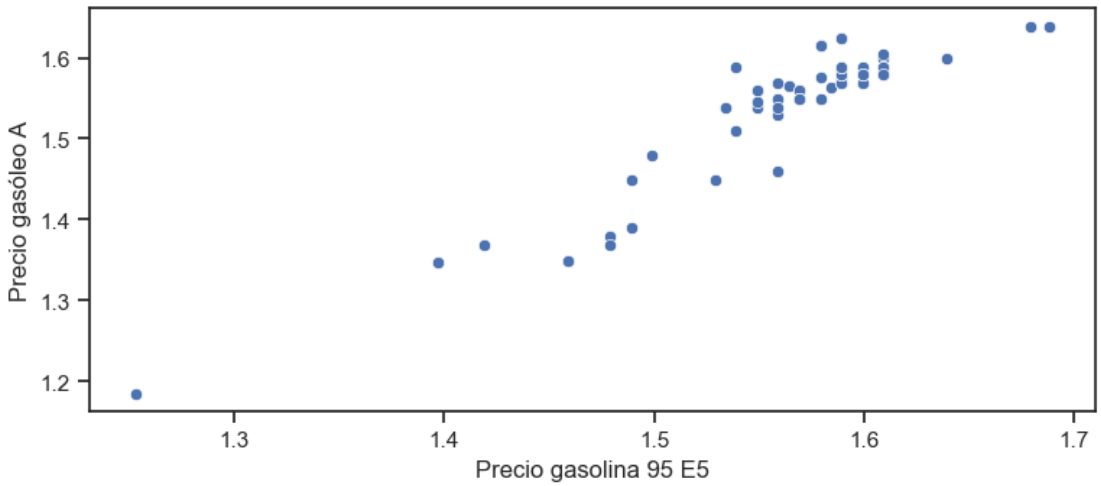
También observamos que hay varios errores en la calidad de los datos (DQ Issue):

- El Precio gasóleo A tiene una correlación muy alta con el Precio gasolina 95 E5. Por ello recomienda la eliminación de una de ellas. Esto se observa en el gráfico de mapa de calor donde la correlación entre el precio de la gasolina 95 y el gasóleo es de 0.94; y también en la gráfica de correlación.





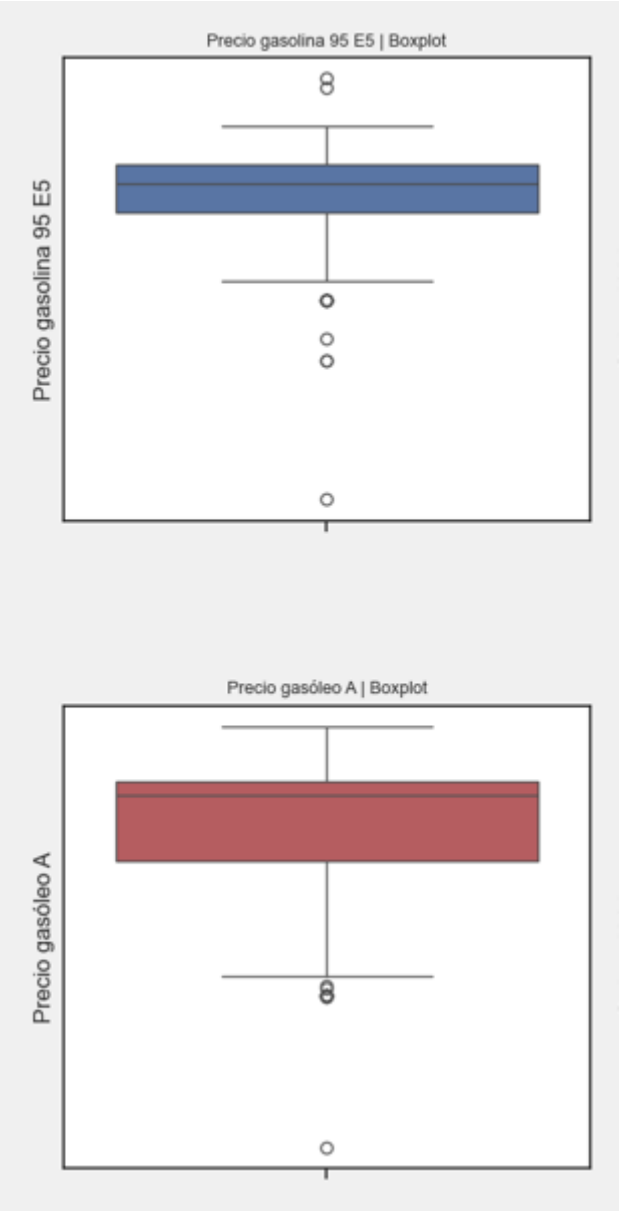
- Se detectan 12 valores atípicos (outliers) fuera de los límites normales, por debajo de 1.47 y por encima de 1.67 en gasolina 95 E5; y por debajo de 1.37 y por encima de 1.71 en gasóleo A. Esto se aprecia en la gráfica de dispersión y también en la de correlación mostrada anteriormente.



- También se indican valores faltantes (11 en gasolina 95 E5, 5 en gasóleo A, y 8 en tipo de servicio). Además, se indica que, en tipo de servicio, hay tipos de datos mezclados: números y texto.

Siguiendo el modelo KDD, procedo a la limpieza de datos. En lugar de eliminar las filas con datos nulos en los precios, imputo un valor basado en la media de la provincia para así solucionar el error y, tras hacerlo, compruebo que ya no existen datos nulos.

Aunque en análisis de los precios es comprensible y fácil de realizar basándose en el precio en euros por litro, he aplicado normalización a los datos mediante mínimo y máximo (0, 1) utilizando la librería sklearn. Antes de realizarla he estudiado los valores marcados como outliers y los he mantenido ya que pueden ser valores reales del mercado.



Para finalizar la limpieza de datos y solucionar el problema de la mezcla de tipos de datos de la columna tipo de servicio, he transformado todos los datos a String para que sean homogéneos.

Como propuesta de aprendizaje automático creo que sería interesante un modelo que, en función del precio de la gasolina, prediga el precio del gasóleo, dado que la correlación de ambos precios es alta.