# Actividad 2. Clasificación mediante árboles de decisión

Aprendizaje automático y minería de datos

Ángel Antón Gaitán

# Actividad 2. Clasificación mediante árboles de decisión

## 1. Introducción y Carga de Datos

El presente informe describe el proceso de creación de un modelo predictivo basado en árboles de decisión para clasificar los niveles de contaminación en la ciudad de Madrid. Se utiliza el dataset *gii32_act2_estaciones_madrid.csv*, el cual contiene registros temporales de diversos contaminantes (SO2, CO, NO, NO2, PM2.5, PM10, etc.) medidos en distintas estaciones de la red de vigilancia municipal.

Para el desarrollo de esta actividad se ha utilizado el lenguaje de programación Python en un entorno de Jupyter Notebook. Las principales librerías empleadas incluyen Pandas y NumPy para el preprocesamiento de datos, Matplotlib y Seaborn para el análisis exploratorio visual, y Scikit-Learn como framework principal para la construcción y validación del modelo de clasificación por árboles de decisión.

## 2. Preprocesamiento y Limpieza

Se ha realizado un análisis de valores ausentes, detectando una presencia significativa de nulos en sensores específicos. Para solventarlo, se ha aplicado una técnica de limpieza basada en la imputación por la media aritmética de cada atributo. Esta transformación es necesaria ya que los algoritmos de la librería sklearn requieren datasets completos para su ejecución.

## 3. Discretización de la Variable Objetivo

Se ha seleccionado el Dióxido de Nitrógeno (*NO2*) como variable a predecir. Para adaptar el problema a un modelo de clasificación, se ha transformado el atributo continuo en una variable categórica denominada 'Nivel_NO2' con tres niveles: Bajo, Medio y Alto. Los umbrales se han definido buscando un equilibrio en la distribución de las clases, permitiendo así que el modelo pueda diferenciar situaciones de baja contaminación frente a episodios de alerta.

## 4. Estudio de Relevancia de Atributos

Se ha generado una matriz de correlación para evaluar la relación lineal entre los distintos contaminantes. Se observa una correlación muy alta entre el $NO_2$ y el $NO_x$, así como con el NO. Para cumplir con las pautas de la actividad, se ha identificado que la variable más correlacionada es $NO_x$. En fases posteriores se analizará el impacto de prescindir de este atributo en la capacidad predictiva del árbol.

## 5. Generación de conjuntos de entrenamiento y test

Se ha procedido a la partición del conjunto de datos siguiendo un esquema de validación mediante un set de prueba independiente. Se ha reservado un 70% de las instancias para el entrenamiento del modelo y un 30% para su posterior evaluación. Para garantizar la reproducibilidad del experimento, se ha fijado la semilla de aleatoriedad mediante el parámetro random_state=1.

## 6. Algoritmo y ajuste de parámetros

Se ha seleccionado el algoritmo DecisionTreeClassifier de la librería Scikit-Learn. Para el entrenamiento, se ha optado por el criterio de entropía (basado en la ganancia de información). Con el fin de evitar el sobreajuste (overfitting), se ha realizado un ajuste estableciendo una profundidad máxima de 5 niveles y un mínimo de 10 muestras por hoja. Esta técnica de prepoda garantiza que el modelo resultante sea interpretable y generalice correctamente ante nuevos datos.

## 7. Visualización del Árbol de Decisión

Se observa en la visualización del árbol que el contaminante NOx es el nodo raíz, siendo el principal discriminador para los niveles de $NO_2$. Las ramas muestran cómo el modelo segmenta los datos basándose en umbrales de concentración de los demás gases[1].

El color de cada nodo representa la clase mayoritaria y su intensidad indica la pureza del mismo (basada en el valor de la entropía):

[1] Ver gráfica en Anexo

- **Verde (Nivel Bajo):** Identifica las situaciones de calidad del aire óptima. Se observa predominantemente en la rama izquierda del árbol, asociada a concentraciones reducidas de precursores.
- **Morado (Nivel Medio):** Representa niveles intermedios de $NO_2$. Es la clase con mayor presencia en los nodos centrales, donde las condiciones de contaminación son moderadas.
- **Naranja/Marrón (Nivel Alto):** Identifica los episodios de alta contaminación. Estos nodos se concentran en la zona derecha del gráfico, vinculados a valores elevados de emisiones.

### Lógica del Nodo Raíz

El algoritmo ha identificado el $NO_x$ como el atributo con mayor ganancia de información. El primer nivel de decisión establece un umbral de 24.5 µg/m³:

- Si el valor de $NO_x$ es ≤ 24.5 (rama izquierda), existe una probabilidad muy alta de que la calidad del aire sea categorizada como "Bajo".
- Si el valor supera dicho umbral (rama derecha), el modelo descarta la categoría "Bajo" y comienza a evaluar si el nivel es "Medio" o "Alto" en función de otros contaminantes como el NO o el $O_3$.

### Evaluación de la Pureza y Entropía:

Los nodos con colores más saturados (especialmente en los extremos del árbol) presentan una entropía cercana a 0. Esto indica que las reglas de decisión en esos puntos son altamente efectivas, logrando separar las instancias de forma casi pura, lo que dota al modelo de una gran seguridad en sus predicciones para situaciones extremas de contaminación.

## 8. Evaluación del Modelo y Métricas de Rendimiento

Tras aplicar el modelo sobre el conjunto de test (datos no vistos durante el entrenamiento), se han obtenido métricas de rendimiento muy sólidas que validan la eficacia del árbol de decisión.

- **Exactitud Global (Accuracy):** El modelo alcanza un **95% de acierto general**. Esto indica una capacidad predictiva muy alta, siendo capaz de clasificar correctamente 95 de cada 100 registros de calidad del aire.
- **Rendimiento por Categorías:**
    - **Nivel Bajo:** Es la clase con mejor rendimiento, alcanzando un F1-score de 0.98. Esto demuestra que el modelo es casi infalible detectando situaciones de baja contaminación.
    - **Nivel Medio:** Presenta un equilibrio perfecto entre precisión y exhaustividad (0.94), gestionando correctamente la mayoría de los casos estándar.
    - **Nivel Alto:** Aunque es la clase con menor soporte (393 muestras), el modelo mantiene un F1-score de 0.90. Es especialmente relevante el Recall (0.91) en esta categoría, ya que indica que el sistema es capaz de detectar el 91% de los episodios de alta contaminación, algo crítico para la salud pública.

### Conclusión de la Evaluación

Los resultados muestran que las métricas de *macro avg* y *weighted avg* están alineadas (0.94 - 0.95), lo que confirma que el modelo es robusto y no presenta sesgos graves a pesar de que las clases no están perfectamente balanceadas. El uso del criterio de entropía y la limitación de la profundidad han permitido obtener un clasificador altamente eficiente y generalizable.

## 9. Experimento de Repercusión: Eliminación del Atributo Principal

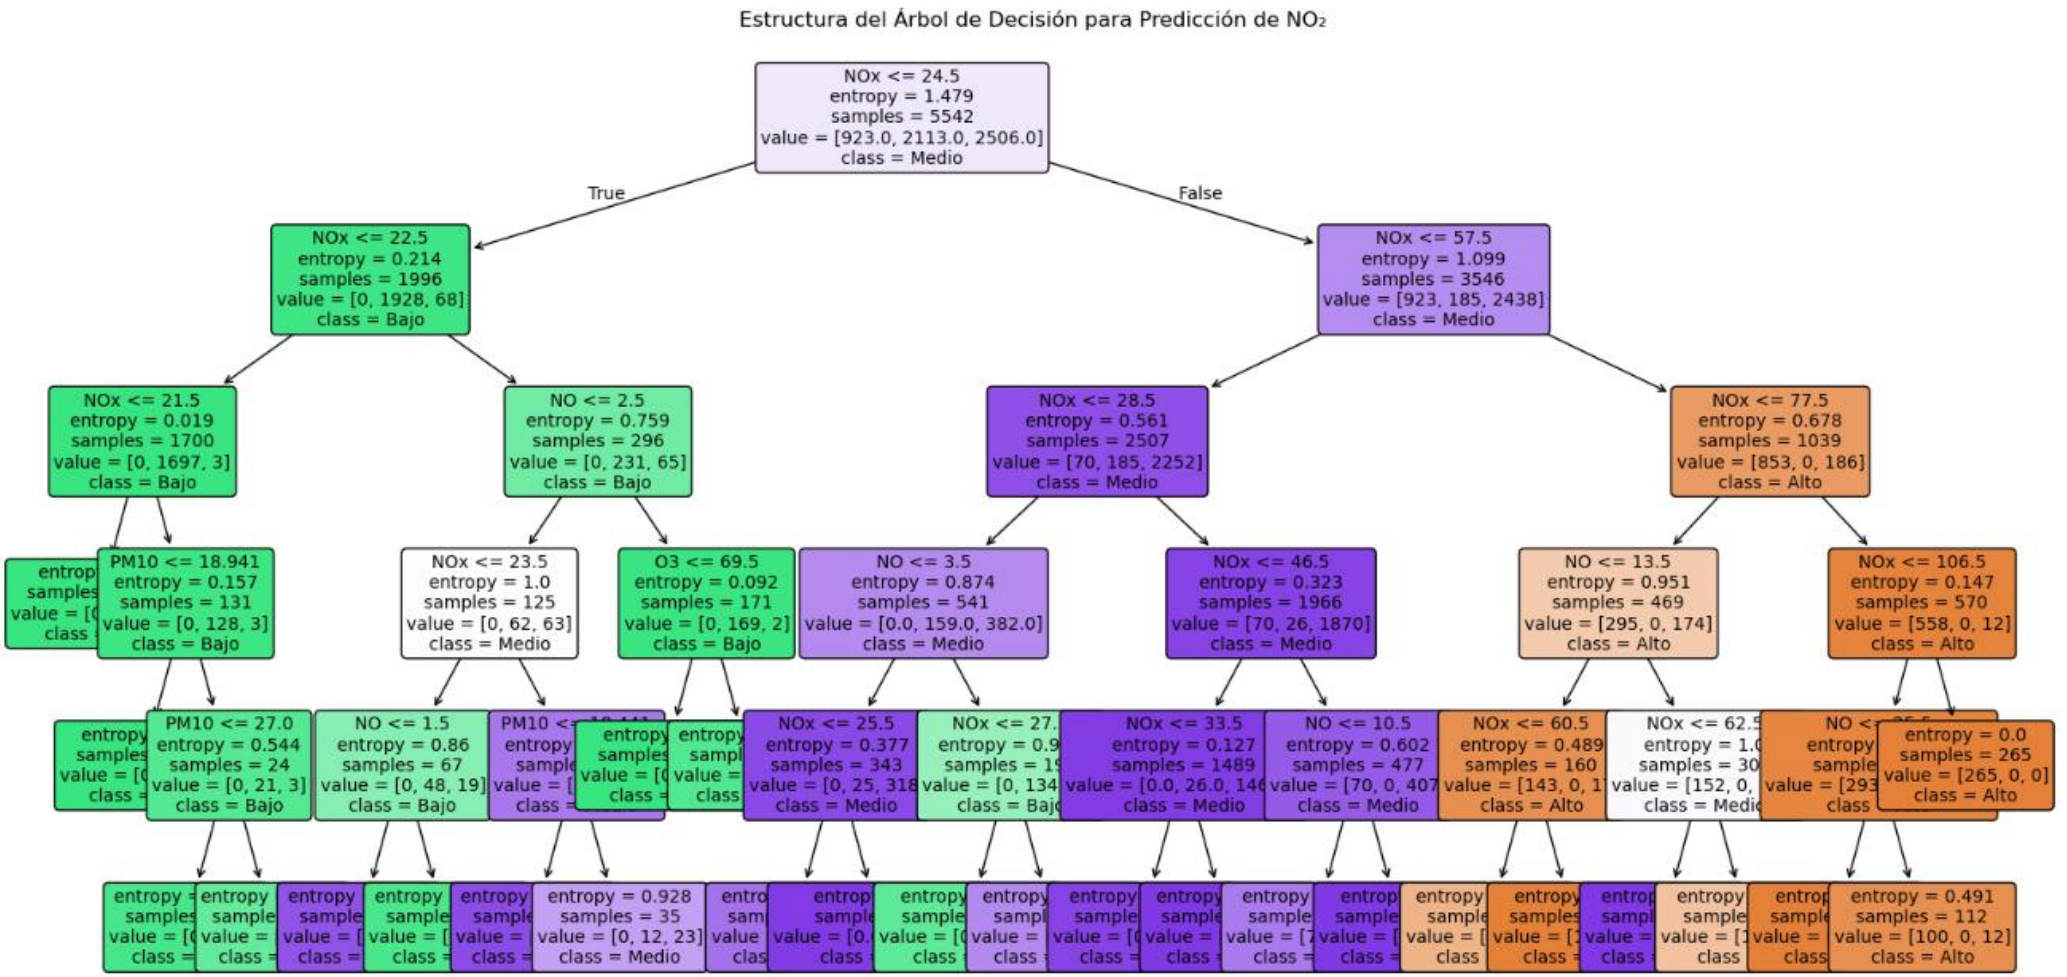
Se ha evaluado la importancia del conjunto de atributos mediante un experimento de exclusión. Tras identificar en el análisis exploratorio que el $NO_x$ es la variable con mayor correlación con el $NO_2$, se ha procedido a entrenar un segundo modelo prescindiendo de dicha variable.

- **Análisis de Repercusión:** Al eliminar el atributo principal, la precisión del modelo ha descendido de un 95% a un 75%. Esta diferencia de un 28% evidencia que el

$NO_x$ contiene información crítica que no puede ser replicada totalmente por el resto de los sensores de contaminantes.

- **Conclusión Final:** El experimento confirma que el conjunto de atributos seleccionado originalmente es el óptimo. La alta dependencia entre los óxidos de nitrógeno analizados justifica mantener el NOx como predictor para garantizar un sistema de alerta de calidad del aire fiable y preciso.

## Anexo


Estructura del Árbol de Decisión para Predicción de NO₂
NOx <= 24.5
entropy = 1.479
samples = 5542
value = [923.0, 2113.0, 2506.0]
class = Medio
True
False
NOx <= 22.5
entropy = 0.214
samples = 1996
value = [0, 1928, 68]
class = Bajo
NOx <= 57.5
entropy = 1.099
samples = 3546
value = [923, 185, 2438]
class = Medio
NOx <= 21.5
entropy = 0.019
samples = 1700
value = [0, 1697, 3]
class = Bajo
NO <= 2.5
entropy = 0.759
samples = 296
value = [0, 231, 65]
class = Bajo
NOx <= 28.5
entropy = 0.561
samples = 2507
value = [70, 185, 2252]
class = Medio
NOx <= 77.5
entropy = 0.678
samples = 1039
value = [853, 0, 186]
class = Alto
PM10 <= 18.941
entropy = 0.157
samples = 131
value = [0, 128, 3]
class = Bajo
NOx <= 23.5
entropy = 1.0
samples = 125
value = [0, 62, 63]
class = Medio
O3 <= 69.5
entropy = 0.092
samples = 171
value = [0, 169, 2]
class = Bajo
NO <= 3.5
entropy = 0.874
samples = 541
value = [0.0, 159.0, 382.0]
class = Medio
NOx <= 46.5
entropy = 0.323
samples = 1966
value = [70, 26, 1870]
class = Medio
NO <= 13.5
entropy = 0.951
samples = 469
value = [295, 0, 174]
class = Alto
NOx <= 106.5
entropy = 0.147
samples = 570
value = [558, 0, 12]
class = Alto
PM10 <= 27.0
entropy = 0.544
samples = 24
value = [0, 21, 3]
class = Bajo
NO <= 1.5
entropy = 0.86
samples = 67
value = [0, 48, 19]
class = Bajo
NOx <= 25.5
entropy = 0.377
samples = 343
value = [0, 25, 318
class = Medio
NOx <= 33.5
entropy = 0.127
samples = 1489
value = [0.0, 26.0, 146
class = Medio
NO <= 10.5
entropy = 0.602
samples = 477
value = [70, 0, 407
class = Medio
NOx <= 60.5
entropy = 0.489
samples = 160
value = [143, 0, 1
class = Alto
entropy = 0.0
samples = 265
value = [265, 0, 0]
class = Alto
entropy = 0.928
samples = 35
value = [0, 12, 23]
class = Medio
entropy = 0.491
samples = 112
value = [100, 0, 12]
class = Alto