Actividad 3. Aprendizaje automático para regresión

Aprendizaje automático y minería de datos

Ángel Antón Gaitán

Actividad 3. Aprendizaje automático para regresión

Carga del conjunto de datos y exploración.

El objetivo de este trabajo es predecir el precio medio de la vivienda (MEDV) utilizando el dataset *Boston Housing*. Debido a la eliminación de este dataset en las versiones recientes de scikit-learn por motivos éticos, los datos se han importado directamente desde el repositorio oficial de la Universidad Carnegie Mellon.

El conjunto de datos consta de 506 muestras y 14 variables. Tras analizar estadísticamente el dataset, se confirma la ausencia total de valores nulos en todas las celdas.

Visualización de la distribución del precio de las viviendas y las relaciones entre las características y el precio utilizando gráficos de dispersión u otras visualizaciones pertinentes

El análisis de la matriz de correlación lineal refleja que los atributos con mayor impacto directo sobre el precio medio (MEDV) son:

- **RM (Número de habitaciones):** Presenta una fuerte correlación positiva (~0.70). A mayor número de habitaciones, el precio de la vivienda se incrementa notablemente.
- **LSTAT (% de población de bajo estatus):** Presenta una fuerte correlación inversa (~ -0.74). A mayor porcentaje de población vulnerable en la zona, el precio medio desciende de forma lineal.

Los gráficos de dispersión confirman estas tendencias, mostrando una relación directamente proporcional para RM e inversamente proporcional para LSTAT, con la presencia de algunos valores atípicos en los extremos superiores de precio.

División del conjunto de datos en características (variables independientes) y la variable objetivo (precio de la vivienda).

Se separan las 13 variables independientes (características socioeconómicas y estructurales del entorno) en la matriz X, aislando la variable dependiente u objetivo y que corresponde al precio medio de la vivienda (MEDV).

División del conjunto de datos en conjuntos de entrenamiento y prueba.

Para garantizar una evaluación objetiva, el conjunto de datos se particiona asignando un 80% de las muestras para el entrenamiento de los modelos (404 registros) y el 20% restante para la fase de prueba o test (102 registros). Se utiliza la semilla aleatoria random_state=42 para asegurar la reproducibilidad.

Regresión Lineal Simple

Se implementa un modelo de regresión lineal utilizando como variable predictora única el número medio de habitaciones (RM), debido a su alta correlación positiva con el precio. El ajuste del modelo se realiza mediante el método de mínimos cuadrados ordinarios sobre el conjunto de entrenamiento.

Al evaluar el comportamiento del modelo con el conjunto de prueba (test), se obtienen las siguientes métricas:

- Error Cuadrático Medio (MSE): 46.1448
- Coeficiente de Determinación (R^2): 0.3708

El coeficiente positivo confirma que por cada habitación adicional el precio estimado de la vivienda aumenta de forma lineal. Sin embargo, el valor de R^2 (0.37) indica que emplear una única variable estructural resulta insuficiente para explicar la variabilidad total del precio de los inmuebles.

Regresión Lineal Múltiple

Se implementa un modelo de regresión lineal multivariable incorporando las 13 características independientes del dataset de forma simultánea. El objetivo de este diseño es permitir que el algoritmo capture la influencia combinada de

factores estructurales, geográficos y socioeconómicos sobre el precio de la vivienda.

Tras el entrenamiento y posterior evaluación con el conjunto de test, se obtienen los siguientes resultados:

- Error Cuadrático Medio (MSE): 24.2911
- Coeficiente de Determinación (R^2): 0.6688

Al comparar estos resultados con el modelo simple, se observa una reducción drástica del error (el MSE baja casi a la mitad) y un incremento notable del R^2 a 0.67. Esto demuestra que el precio de los inmuebles está multideterminado y que la inclusión de todo el espectro de variables mejora significativamente la capacidad predictiva.

Árbol de Regresión

Se implementa un modelo basado en Árboles de Decisión para capturar relaciones de carácter no lineal entre los atributos y el precio de la vivienda. Atendiendo a las exigencias de optimización de la práctica (Criterio 2), se realiza un ajuste de parámetros evaluando el impacto de la profundidad máxima del árbol (max_depth) para mitigar el riesgo de sobreajuste (*overfitting*):

- Configuración con max_depth=2: Produce un modelo demasiado rígido (*underfitting*) con un MSE de 25.9932 y un R^2 de 0.6455.
- Configuración seleccionada con max_depth=5: Ofrece un balance óptimo. Estabiliza el rendimiento en el conjunto de prueba obteniendo un MSE de 8.5539 y un R^2 de 0.8834.

El ajuste del parámetro demuestra que limitar la complejidad del árbol a una profundidad de 5 permite segmentar los datos de forma eficaz, logrando el mejor desempeño predictivo entre todos los modelos evaluados hasta el momento.

Predicción de más de una variable

Atendiendo a las opciones del Criterio 4 de la rúbrica, se expande el alcance del proyecto desarrollando un modelo de regresión con más de una variable. El objetivo consiste en predecir simultáneamente dos variables objetivo continuas

de naturaleza muy distinta a partir del resto de características: el precio medio de la vivienda (MEDV) y la tasa de criminalidad per cápita de la zona (CRIM).

Utilizando la arquitectura de Árbol de Regresión (max_depth=5), el modelo arroja las siguientes métricas en el conjunto de prueba de manera síncrona:

- Predicción de Precio (MEDV): MSE de 10.1403 y un R^2 de 0.8617.
- Predicción de Criminalidad (CRIM): MSE de 66.5988 y un R^2 de -0.2087.

La predicción simultánea eleva la dificultad del caso: mientras que el precio de la vivienda mantiene una precisión excelente (R^2 de 0.86), la tasa de criminalidad arroja un R^2 negativo. Esto evidencia que el comportamiento delictivo de una zona no puede explicarse eficazmente utilizando únicamente variables de carácter inmobiliario o estructural, un hallazgo de alto valor analítico que justifica la complejidad del experimento.

Tabla comparativa y conclusiones

A continuación, se contrastan los resultados obtenidos por todos los algoritmos aplicados sobre el conjunto de datos de prueba:

Algoritmo / Modelo	Variable(s) Objetivo	Parámetros / Ajuste	MSE	R2
Regresión Lineal Simple	MEDV	Predictor único: RM	46.1448	0.3708
Regresión Lineal Múltiple	MEDV	13 Características	24.2911	0.6688
Árbol de Regresión (Óptimo)	MEDV	max_depth = 5	8.5539	0.8834
Árbol Multi-salida (Adicional)	MEDV y CRIM	max_depth = 5	10.1403 / 66.5988	0.8617 / -0.2087

Los modelos lineales tradicionales asumen rigidez en las relaciones de los datos. La transición de una regresión simple a una múltiple demuestra que el precio de la vivienda está multideterminado por varios factores, reduciendo el error a la mitad.

El Árbol de Regresión (max_depth=5) fue el algoritmo con mejor rendimiento global para predecir el precio de la vivienda, alcanzando el menor error (MSE: 8.5539) y la mayor capacidad de explicación de variabilidad (R^2: 0.8834). Esto demuestra que las estructuras basadas en reglas no lineales se adaptan mucho mejor a la complejidad del mercado inmobiliario que las funciones lineales.

El experimento con varias variables confirmó la versatilidad de los árboles de decisión para realizar predicciones paralelas, desvelando a su vez que variables como la seguridad ciudadana (CRIM) requieren de atributos contextuales ajenos al entorno puramente habitacional para ser estimados con precisión.